

R でベイズ線形回帰

宇佐美雅紀

2014/12/01

1 はじめに

この資料は、第 8 回 機械学習勉強会で勉強した、ベイズ線形回帰を R 言語を使って実装する例を説明するものです。参考にしたのは、以下のブログです。

Mimanca qualche giovedì?

R でベイズ線形回帰の予測分布 (2009-07-09 付)

http://d.hatena.ne.jp/n_shuyo/20090709/predictive

ソースコードは、丸ごとコピーです。宇佐美のオリジナリティはありません。

コンセプトは、「他人のふんどしで相撲をとる」です。

2 PRML 3.3.2 章 予測分布のおさらい

教科書の 3.3.2 章で解説している予測分布の式をおさらいします。予測分布の式は以下のようになります (教科書 3.58 式)。

$$p(t|\mathbf{x}, \mathbf{t}, \mathbf{S}) = N(t|\mathbf{m}_N^T(\mathbf{x}), \sigma_N^2(\mathbf{x})) \quad (1)$$

ここで、予測分布の分散 $\sigma_N^2(x)$ は、以下の式で与えられます (教科書 3.59 式)。

$$\sigma_N^2(\mathbf{x}) = \frac{1}{\sigma^2} + \mathbf{x}^T \mathbf{S}_N^{-1} \mathbf{x} \quad (2)$$

また、 \mathbf{m}_N 、 \mathbf{S}_N^{-1} はそれぞれ教科書 3.53 式、3.54 式から以下のように与えられます。

$$\mathbf{m}_N = \mathbf{S}_N^{-1} \mathbf{t} \quad (3)$$

$$\mathbf{S}_N^{-1} = \mathbf{I} + \mathbf{S}^{-1} \mathbf{x} \mathbf{x}^T \quad (4)$$

基底関数はガウス基底関数を使用します (教科書 3.4 式)。ここで μ_j は入力空間における基底関数の位置を表し、パラメータ s は空間的な尺度を表す、と教科書には書いてますがイマイチよくわかりません。

$$j(x) = \exp\left\{-\frac{(x - \mu_j)^2}{2s^2}\right\} \quad (5)$$

念のためガウス分布の定義もおさらいします (教科書 1.47 式)。 μ は平均、 σ^2 が分散。

$$N(x | \mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\} \quad (6)$$

3 R のソースコード

```
#####
#
# Usage: R --vanilla --slave < linear_regression.r
#       http://d.hatena.ne.jp/n_shuyo/20090709/predictive
#
#####

M <- 9          # number of basis function
alpha <- 2      # hyper parameter
beta <- 25      # hyper parameter
Lattice <- 30   # number of graph's lattice
s<-0.1
u_i<-0.5

# training data
xlist <- seq(0, 1, length=25)
tlist <- sin(2*pi*xlist) + rnorm(length(xlist), sd=0.2)
D0 <- data.frame(x=xlist, t=tlist)

predictive <- function(D) {
  # design matrix
  phi <- function(x) sapply(x,function(x){exp(-(x-seq(0,1,length=9))^2/(2*s*s))})
  PHI <- t(phi(D$x))

  # covariance matrix & means
  S_N_inv <- alpha * diag(9) + beta * t(PHI) %*% PHI
  S_N <- solve(S_N_inv)
  m_N <- beta * S_N %*% t(PHI) %*% D$t

  # regression function
  y <- function(x)(t(phi(x)) %*% m_N)
  plot(y, xlim=c(0,1), ylim=c(-1.2, 1.2))
  par(new=T)
  plot(D, xlim=c(0,1), ylim=c(-1.2, 1.2), ylab="")

  # predictive distribution
  var_N <- function(x) {1/beta + (t(phi(x)) %*% S_N %*% phi(x))[1]}
  function(x,t) {
    mapply(function(x,t)dnorm(t,m=(t(m_N) %*% phi(x))[1], s=var_N(x), log=T), x, t)
  }
}

draw_dist <- function(p){
  x <- seq(0, 1, length=Lattice)
  t <- seq(-1.5, 1.5, length=Lattice*2)
  z <- outer(x, t, p)
  persp(x, t, z, theta=0, phi=60, shade=0.4)
}
```

```

p <- predictive(D0[sample(length(D0$x))[1:1],])
draw_dist(p);
p <- predictive(D0[sample(length(D0$x))[1:2],])
draw_dist(p);
p <- predictive(D0[sample(length(D0$x))[1:4],])
draw_dist(p);
p <- predictive(D0)
draw_dist(p);

```

4 解説

4.1 計画行列

ガウス基底関数をおさらいします。

$$j(x) = \exp\left\{-\frac{(x - u_j)^2}{2s^2}\right\} \quad (7)$$

計画行列のおさらいです。

$$= \begin{pmatrix} 0(\mathbf{x}_1) & 1(\mathbf{x}_1) & \dots & M-1(\mathbf{x}_1) \\ 0(\mathbf{x}_2) & 1(\mathbf{x}_2) & \dots & M-1(\mathbf{x}_2) \\ \dots & \dots & \dots & \dots \\ 0(\mathbf{x}_N) & 1(\mathbf{x}_N) & \dots & M-1(\mathbf{x}_N) \end{pmatrix} \quad (8)$$

```

# design matrix
phi <- function(x) sapply(x,function(x){exp(-(x-seq(0,1,length=9))^2/(2*s*s))})
PHI <- t(phi(D$x))

```

計画行列に相当する部分のソースコードです。

phi の後半部分は、ガウス基底関数そのままであることがわかります。ガウス基底関数の μ_j 部分が `seq(0,1,length=9)` に変更されています。これは、パラメータ μ_j を $[0,1]$ で 9 等分にすることを意味しています。これでガウス基底関数部分はスカラー値 x を与えると、ベクトル値が返る関数になります。sapply は、リストに関数を適用して行列を返す関数なので、phi にリストを与えると行列が返ります。

phi(D\$x) で、データフレーム D の x 列を phi 関数に適用して、計画行列を作ります。t 関数は行列を転置してくれる関数です。

4.2 共分散&平均行列

共分散 S_N と平均行列 M_N をおさらいします。

$$\mathbf{m}_N = \mathbf{S}_N^{-1} \mathbf{t} \quad (9)$$

$$\mathbf{S}_N^{-1} = \mathbf{I} + \mathbf{T} \quad (10)$$

```

# covariance matrix & means
S_N_inv <- alpha * diag(9) + beta * t(PHI) %*% PHI
S_N <- solve(S_N_inv)
m_N <- beta * S_N %*% t(PHI) %*% D$t

```

共分散 S_N と平均行列 M_N に相当する部分のソースコードです。

diag は単位行列を作る関数です。solve は逆行列を求める関数です。

ハイパーパラメータの α と β は、ソースコードの最初で定数として定義されています。

4.3 予測分布

予測分布の式をおさらいします。

$$p(t|\mathbf{x}, \mathbf{t}, \mathbf{S}_N, \mathbf{M}_N) = N(t | \mathbf{m}_N^T \phi(\mathbf{x}), \sigma_N^2(\mathbf{x})) \quad (11)$$

予測分布の分散 $\sigma_N^2(x)$ の式をおさらいします。

$$\sigma_N^2(\mathbf{x}) = \frac{1}{\beta} + \phi(\mathbf{x})^T \mathbf{S}_N \phi(\mathbf{x}) \quad (12)$$

```
# predictive distribution
var_N <- function(x) {1/beta + (t(phi(x)) %*% S_N %*% phi(x))[1]}
function(x,t) {
  mapply(function(x,t)dnorm(t,m=(t(m_N) %*% phi(x))[1], s=var_N(x), log=T), x, t)
}
```

予測分布の式に相当する部分のソースコードです。

分散の関数は、式そのままです。

dnorm 関数は、正規分布の確率密度です。